

**TRƯỜNG ĐẠI HỌC VĂN LANG
KHOA CÔNG NGHỆ THÔNG TIN**



**NHẬP MÔN PHÂN TÍCH DỮ LIỆU VÀ HỌC SÂU
NGÀNH: CÔNG NGHỆ THÔNG TIN**

Đề tài:

Phân tích dữ liệu về Covid-19 của toàn cầu

SVTH:

**2274802010773 - Nguyễn Thành Tài
197ct09825 – Bùi Đức Thành Long
2274802010470 – Nguyễn Quốc Lâm**

**GVHD: Thầy HUỲNH THÁI HỌC
LHP: 242_71ITDS30203_05**

Mục Lục

<i>Giới Thiệu:</i>	4
1.1 Giới thiệu tổng quan về đại dịch COVID-19	4
1.2 Mục tiêu và phạm vi phân tích	4
1.2.1 Mục tiêu:	4
1.2.2 Phạm vi phân tích:	4
1.3 Dữ liệu sử dụng:	4
1.3.1 Dữ liệu:	4
1.3.2 Cấu trúc dữ liệu:	5
2 Chuẩn bị dữ liệu	6
2.1 Nhập và khám phá dữ liệu ban đầu:	6
2.2 Tiền xử lý dữ liệu:	7
2.2.1 Xử lý giá trị thiếu:	7
2.2.2 Tạo các cột và tính toán mới:	8
2.2.3 Tính toán các giá trị:	9
3 Phân tích dữ liệu khám phá (EDA):	10
3.1 Tổng quan toàn cầu:	10
3.1.1 Phân tích số ca nhiễm, ca tử vong:	11
3.1.2 Trực quan hoá dữ liệu:	12
3.2 Phân tích tương quan	15
3.2.1 Tìm hiểu mối quan hệ giữa các biến số	15
4 Kết luận và thảo luận:	16
4.1 Tóm tắt kết quả phân tích:	16
4.2 Đánh giá những hạn chế của phân tích:	16
4.3 Đề xuất các hướng nghiên cứu tiếp theo:	16
5 Tài liệu tham khảo	16

Phụ lục hình ảnh

Hình 1	Nhập và khám phá dữ liệu ban đầu.....	6
Hình 2	Dữ liệu ban đầu.....	6
Hình 3	Tiền xử lí dữ liệu.....	7
Hình 4	Kiểm tra giá trị "null"	7
Hình 5	Kiểm tra giá trị "NaN"	8
Hình 6	Điền các giá trị còn thiếu	8
Hình 7	Tính tỉ lệ tử vong "Mortality Rate"	9
Hình 8	Thống kê các giá trị.....	9
Hình 9	Biểu đồ thống kê các giá trị	10
Hình 10	Tính Z-Score	10
Hình 11	Biểu đồ cột biểu diễn tổng quan toàn cầu	11
Hình 12	Biểu đồ phân tán giữa ca mắc và tử vong.....	11
Hình 13	Biểu đồ heatmap	12
Hình 14	Biểu đồ Histogram mô tả phân bố số ca mắc.....	13
Hình 15	Biểu đồ Histogram mô tả phân bố số ca tử vong.....	14
Hình 16	Biểu đồ cột biểu diễn số ca mắc và tử vong theo vùng lãnh thổ.....	15

Giới Thiệu:

1.1 Giới thiệu tổng quan về đại dịch COVID-19

COVID-19, viết tắt của Coronavirus Disease 2019, là một bệnh truyền nhiễm do virus SARS-CoV-2 gây ra. Dịch bệnh được phát hiện bùng phát đầu tiên từ thành phố Vũ Hán, tỉnh Hồ Bắc, Trung Quốc vào tháng 12 năm 2019 và nhanh chóng lan rộng ra toàn cầu, gây ra đại dịch chưa từng có trong lịch sử hiện đại.

1.2 Mục tiêu và phạm vi phân tích

1.2.1 Mục tiêu:

Hiểu rõ về sự lây lan của Covid-19 trên toàn cầu:

Phân tích số ca nhiễm, hồi phục và tử vong theo từ quốc gia, châu lục. Đánh giá tỉ lệ tử vong và các yếu tố ảnh hưởng đến nó. So sánh hiệu quả của các chiến lược xét nghiệm giữa từng quốc gia.

Xác định rõ các yếu tố ảnh hưởng đến mức độ nghiêm trọng của dịch bệnh:

Phân tích mối quan hệ giữa dân số và số ca nhiễm, phục hồi, tử vong. Đánh giá tác động của các yếu tố địa lý đến sự lây lan của dịch bệnh. Phân tích các giá trị Z-Score của các thuộc tính, để xem mức độ lệch của các quốc gia so với trung bình tập dữ liệu.

Đánh giá hiệu quả của các biện pháp phòng chống dịch bệnh:

So sánh tỷ lệ phục hồi giữa các quốc gia. Phân tích mối quan hệ giữa số lượng xét nghiệm và số ca nhiễm, phục hồi, tử vong.

1.2.2 Phạm vi phân tích:

Phân tích dữ liệu theo quốc gia và châu lục. So sánh tình hình dịch bệnh giữa các khu vực địa lý khác nhau.

Phân tích dữ liệu tại thời điểm cụ thể (30/06/2024) thời điểm tổng hợp lại số liệu trên toàn cầu

1.3 Dữ liệu sử dụng:

1.3.1 Dữ liệu:

Link: <https://www.kaggle.com/datasets/sanaafrine/covid-19-dataset/data>

Bộ dữ liệu ghi lại thông tin về tình đại dịch Covid-19 tại nhiều quốc gia và vùng lãnh thổ trên thế giới, tính đến ngày 30/06/2024

Cung cấp các chỉ số quan trọng đến dịch bệnh như số ca nhiễm, số ca hồi phục, số ca tử vong và số lần xét nghiệm đã thực hiện.

1.3.2 Cấu trúc dữ liệu:

Dữ liệu được định dạng dưới dạng bảng (CSV) bao gồm 238 dòng và 9 cột, với các cột sau:

country: Tên quốc gia hoặc vùng lãnh thổ.

continent: Tên châu lục

population: Dân số của quốc gia hoặc vùng lãnh thổ

day: Ngày ghi nhận dữ liệu

time: Thời gian ghi nhận dữ liệu

Cases: Số ca nhiễm Covid-19

Recovered: Số ca đã hồi phục

Deaths: Số ca đã tử vong

Test: Số lượng xét nghiệm Covid-19 đã được thực hiện

2 Chuẩn bị dữ liệu

2.1 Nhập và khám phá dữ liệu ban đầu:

```
# Thêm thư viện cần thiết:
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import plotly.express as px
import plotly.graph_objs as go
from scipy import stats

# Khai báo file csv:
df = pd.read_csv("covid_19.csv")

# Đọc file
df
✓ 0.0s
```

Hình 1 Nhập và khám phá dữ liệu ban đầu

Cài đặt các thư viện cần thiết như: pandas, numpy, matplotlib.pyplot, seaborn, plotly.express, plotly.graph_obj,...

Khai báo dữ liệu ban đầu với tên “covid_19.csv” và đọc dữ liệu.

	country	continent	population	day	time	Cases	Recovered	Deaths	Tests
0	Saint-Helena	Africa	6115.0	2024-06-30	2024-06-30T16:15:16+00:00	2166	2.0	NaN	NaN
1	Falkland-Islands	South-America	3539.0	2024-06-30	2024-06-30T16:15:16+00:00	1930	1930.0	NaN	8632.0
2	Montserrat	North-America	4965.0	2024-06-30	2024-06-30T16:15:16+00:00	1403	1376.0	8.0	17762.0
3	Diamond-Princess	NaN	NaN	2024-06-30	2024-06-30T16:15:16+00:00	712	699.0	13.0	NaN
4	Vatican-City	Europe	799.0	2024-06-30	2024-06-30T16:15:16+00:00	29	29.0	NaN	NaN
...	...	...	...	...	...	...	...	...	...
233	Argentina	South-America	46010234.0	2024-06-30	2024-06-30T16:15:10+00:00	10128845	9997258.0	130841.0	35716069.0
234	Netherlands	Europe	17211447.0	2024-06-30	2024-06-30T16:15:10+00:00	8635786	8612599.0	22992.0	25984435.0
235	Mexico	North-America	131562772.0	2024-06-30	2024-06-30T16:15:10+00:00	7702809	6899865.0	334958.0	20013810.0
236	Iran	Asia	86022837.0	2024-06-30	2024-06-30T16:15:10+00:00	7627186	NaN	146811.0	57320267.0
237	Indonesia	Asia	279134505.0	2024-06-30	2024-06-30T16:15:10+00:00	6829221	6647104.0	162063.0	114158919.0

238 rows x 9 columns

Hình 2 Dữ liệu ban đầu

2.2 Tiền xử lí dữ liệu:

2.2.1 Xử lý giá trị thiếu:

```
#Làm sạch dữ liệu, xoá bỏ những hàng không đủ dữ liệu và dữ liệu không đúng mục tiêu:  
# Xóa dòng 3 và 6, vì là tàu du lịch chứ không phải quốc gia  
df = df.drop([3, 6])  
  
# Xóa các hàng có giá trị NaN ở cả hai cột 'Recovered' và 'Deaths'  
df = df.dropna(subset=['Recovered', 'Deaths'], how='all')  
  
# Reset lại index sau khi xóa dòng  
df = df.reset_index(drop=True)  
  
df  
✓ 0.0s
```

Hình 3 Tiền xử lí dữ liệu

Làm sạch dữ liệu, xoá bỏ các giá trị không đúng với mục tiêu phân tích, và các hàng có nhiều giá trị còn thiếu không đủ dữ liệu để phân tích một cách chính xác.

Kiểm tra các hàng có giá trị “null” và “NaN”:

```
#Kiểm tra các giá trị null:  
df.isnull().sum()#Xem số lượng giá trị null trong mỗi cột.  
✓ 0.0s  
  
country      0  
continent    0  
population    7  
day           0  
time         0  
Cases        0  
Recovered    47  
Deaths       4  
Tests       22  
dtype: int64
```

Hình 4 Kiểm tra giá trị "null"

```
# Kiểm tra các hàng có giá trị NaN trong cột "population"
nan_rows = df[df['population'].isnull()]

# In ra các hàng có giá trị NaN
print(nan_rows)
```

✓ 0.0s

	country	continent	population	day	\
209	North-America	North-America	NaN	2024-06-30	
210	Asia	Asia	NaN	2024-06-30	
211	Europe	Europe	NaN	2024-06-30	
212	South-America	South-America	NaN	2024-06-30	
213	Oceania	Oceania	NaN	2024-06-30	
214	Africa	Africa	NaN	2024-06-30	
215	All	All	NaN	2024-06-30	

Hình 5 Kiểm tra giá trị "NaN"

2.2.2 Tạo các cột và tính toán mới:

Tạo thêm cột tỉ lệ tử vong “Mortality Rate” và điền vào các giá trị còn thiếu trong dữ liệu bằng logic, tham khảo trên các trang thống kê chính thống và sử dụng các thuật toán cơ bản, để điền đầy đủ các giá trị, đầy đủ thông tin cho việc phân tích dữ liệu.

```
#Điền giá trị còn thiếu trong cột Recovered bằng số ca mắc trừ số ca đã tử vong:
df['Recovered'].fillna(df['Cases'] - df['Deaths'], inplace=True)

#Điền giá trị null trong cột death = cases - recovered
df['Deaths'] = df["Deaths"].fillna(df["Cases"] - df["Recovered"])

#Điền giá trị null trong cột test bằng giá trị trung bình của cột:
df["Tests"] = df["Tests"].fillna(df["Tests"].mean())

# Dữ liệu dân số(Tham khảo từ:World Bank Open Data)
population_data = {
    209: 600000000,
    210: 4700000000,
    211: 748000000,
    212: 436000000,
    213: 43000000,
    214: 1400000000,
    215: 800000000
}

# Điền dữ liệu vào cột "population"
for index, population in population_data.items():
    df.loc[index, "population"] = population

df.isnull().sum()

df
```

✓ 0.0s

Hình 6 Điền các giá trị còn thiếu


```
#Tính tỉ lệ tử vong trên số ca nhiễm:
df['Mortality Rate'] = (df['Deaths'] / df['Cases']) * 100

print(df["Mortality Rate"])
✓ 0.0s
```

0	99.907664
1	0.000000
2	0.570207
3	0.000000
4	10.000000
...	
230	1.291766
231	0.266241
232	4.348518
233	1.924838
234	2.373082

Name: Mortality Rate, Length: 235, dtype: float64

Hình 7 Tính tỉ lệ tử vong "Mortality Rate"

2.2.3 Tính toán các giá trị:


Thống kê các giá trị count, mean, std, min , max, 25%, 50%, 75%:

```
#Thống kê các giá trị:
df.describe().T #Thống kê các giá trị trung bình, độ lệch chuẩn, min, max,... cho các cột số.
✓ 0.0s
```

	count	mean	std	min	25%	50%	75%	max
population	235.0	1.015827e+08	6.249593e+08	799.0	582254.5	6684849.0	27826923.0	8.000000e+09
Cases	235.0	8.996852e+06	5.225233e+07	10.0	29125.5	234174.0	1658259.0	7.047539e+08
Recovered	235.0	8.693046e+06	5.014370e+07	2.0	25995.5	228805.0	1631805.0	6.756198e+08
Deaths	235.0	8.950715e+04	5.141976e+05	0.0	225.0	2349.0	17594.5	7.010681e+06
Tests	235.0	3.298829e+07	1.141036e+08	7850.0	420750.5	3078533.0	29673910.0	1.186852e+09

Hình 8 Thống kê các giá trị

Biểu diễn các giá trị bằng biểu đồ:



Hình 9 Biểu đồ thống kê các giá trị

Tính giá trị Z-Score:

```
# Các cột số cần tính z-score
numeric_columns = ['population', 'Cases', 'Recovered', 'Deaths', 'Tests']

# Tính z-score cho từng cột số
for col in numeric_columns:
    z_col_name = f'Z-{col}'
    df[z_col_name] = stats.zscore(df[col])

z_columns = ['Z-population', 'Z-Cases', 'Z-Recovered', 'Z-Deaths', 'Z-Tests']

for col in z_columns:
    if col in df.columns: #kiểm tra xem cột z-score có tồn tại không.
        df[col] = df[col].round(3) # Làm tròn đến 3 chữ số thập phân

df
✓ 0.0s
```

Hình 10 Tính Z-Score


3 Phân tích dữ liệu khám phá (EDA):

3.1 Tổng quan toàn cầu:

Tổng số ca nhiễm: 2,1 tỷ ca

Tổng số ca tử vong: 21 triệu ca (Tỷ lệ tử vong: ~0,99%)

Số quốc gia/vùng lãnh thổ: 236 quốc gia/ 6 vùng lãnh thổ



Hình 11 Biểu đồ cột biểu diễn tổng quan toàn cầu

3.1.1 Phân tích số ca nhiễm, ca tử vong:

Phần lớn các nước có số ca nhiễm thấp, chỉ một vài nước có số ca cực cao.


Ví dụ: Mỹ có hơn 111 triệu ca, nhưng nhiều quốc gia bé như Vatican-City chỉ có 29 ca.

- COVID-19 không ảnh hưởng đồng đều. Một số nước bị nặng (Mỹ, Châu Âu), một số nước gần như không đáng kể.

Phần lớn các nước có số ca tử vong rất thấp (dưới 2.570 ca).

Nhưng vẫn có những nước cực kỳ nghiêm trọng như Mỹ với hơn 1,2 triệu người tử vong.

Tỷ lệ tử vong không đồng đều: Một số nước y tế tốt nên số người chết ít, nhưng có những nước tử vong nhiều hơn. Một số nước không ghi nhận ca tử vong như Vatican-City hay Tokelau.



Hình 12 Biểu đồ phân tán giữa ca mắc và tử vong

3.1.2 Trực quan hoá dữ liệu:

Châu lục	Số ca nhiễm	Số ca tử vong	Tỷ lệ tử vong
Châu Phi	25,7 triệu	517.784	2,01%
Châu Á	443 triệu	3,1 triệu	0,70%
Châu Âu	506,8 triệu	4,2 triệu	0,83%
Bắc Mỹ	263,8 triệu	3,4 triệu	1,29%
Nam Mỹ	140,4 triệu	2,7 triệu	1,95%
Châu Đại Dương	29,8 triệu	66.030	0,22%

Châu Âu và Châu Á có số ca nhiễm nhiều nhất.

Nhưng Châu Phi có tỷ lệ tử vong cao nhất (~2,01%), cho thấy hệ thống y tế chưa tốt.

Châu Phi: Ít ca nhiễm nhưng nguy hiểm hơn vì tỷ lệ tử vong cao.

Châu Đại Dương: Kiểm soát dịch tốt nhất với tỷ lệ tử vong thấp (~0,22%).


Phân tích Heatmap số ca mắc theo châu lục và dân số

Heatmap thể hiện mối quan hệ giữa số ca mắc COVID-19 theo từng châu lục và quy mô dân số:

Mỹ và Ấn Độ chiếm phần lớn số ca mắc do dân số lớn và mật độ tiếp xúc cao.


Châu Phi tuy có dân số đông nhưng số ca thấp hơn do khả năng xét nghiệm hạn chế.

Châu Đại Dương có số ca thấp nhờ các biện pháp kiểm soát nghiêm ngặt.




Hình 13 Biểu đồ heatmap

Biểu đồ histogram sẽ giúp đánh giá mức độ lan truyền của dịch bệnh, biểu đồ scatter giúp xác định liệu có mối quan hệ tuyến tính giữa số ca mắc và số ca tử vong hay không, Heatmap giúp đánh giá sự tương quan giữa các biến số như dân số, số ca mắc, số ca tử vong.



Hình 14 Biểu đồ Histogram mô tả phân bố số ca mắc


Biểu đồ đầu tiên mô tả phân bố số ca mắc COVID-19 giữa các quốc gia. Trên trục hoành là số ca mắc, còn trên trục tung thể hiện số lượng quốc gia có số ca mắc nằm trong từng khoảng giá trị. Nếu quan sát thấy đa số các quốc gia có số ca mắc thấp nhưng vẫn có một số ít quốc gia có số ca rất cao, điều này cho thấy dịch bệnh không lây lan đồng đều trên toàn thế giới. Một số quốc gia như Mỹ, Ấn Độ hay Brazil có thể thuộc nhóm có số ca mắc cao nhất, trong khi phần lớn các quốc gia khác có số ca mắc thấp hơn nhiều.



Hình 15 Biểu đồ Histogram mô tả phân bố số ca tử vong

Tương tự, biểu đồ thứ hai thể hiện phân bố số ca tử vong do COVID-19. Nếu đa số các quốc gia có số ca tử vong thấp nhưng có một số ít nước ghi nhận số ca tử vong rất cao, điều này phản ánh sự khác biệt trong cách kiểm soát dịch bệnh và chất lượng hệ thống y tế giữa các nước. Các quốc gia có số ca tử vong cao thường là những nước có dân số lớn hoặc đã trải qua những đợt bùng phát nghiêm trọng.

Nhìn chung, từ hai biểu đồ này, có thể thấy rằng dịch COVID-19 có sự tác động không đồng đều giữa các quốc gia. Một số nước có khả năng kiểm soát tốt, trong khi một số khác chịu ảnh hưởng nặng nề với số ca mắc và tử vong rất cao. Điều này có thể do nhiều yếu tố như quy mô dân số, chính sách phòng dịch, mức độ tiêm chủng hay hệ thống y tế của từng quốc gia.



Hình 16 Biểu đồ cột biểu diễn số ca mắc và tử vong theo vùng lãnh thổ

Châu Âu và Châu Á có số ca nhiễm nhiều nhất.

Nhưng Châu Phi có tỷ lệ tử vong cao nhất (~2,01%), cho thấy hệ thống y tế chưa tốt.

Châu Phi: Ít ca nhiễm nhưng nguy hiểm hơn vì tỷ lệ tử vong cao.

Châu Đại Dương: Kiểm soát dịch tốt nhất với tỷ lệ tử vong thấp (~0,22%).

3.2 Phân tích tương quan :

3.2.1 Tìm hiểu mối quan hệ giữa các biến số:

Sử dụng ma trận tương quan để đánh giá mối quan hệ giữa các biến số số học. Kết quả thu được như sau:

Biến số 1	Biến số 2	Hệ số tương quan
Số ca mắc	Số ca hồi phục	0.9999
Số ca mắc	Số ca tử vong	0.9856
Số ca hồi phục	Số ca tử vong	0.9862
Số ca mắc	Số xét nghiệm	0.8379
Dân số	Số xét nghiệm	0.5406

Nhận xét:

- Số ca mắc có mối quan hệ rất chặt chẽ với số ca hồi phục và số ca tử vong.
- Quốc gia có nhiều xét nghiệm thường phát hiện được nhiều ca mắc hơn.
- Dân số có tác động đến số xét nghiệm, nhưng không phải là yếu tố quyết định hoàn toàn.

4 Kết luận và thảo luận:

Quá trình phân tích dữ liệu COVID-19 đã giúp chúng ta có cái nhìn tổng quan và chi tiết về tình hình dịch bệnh trên toàn cầu. Dưới đây là những điểm quan trọng rút ra từ dữ liệu.

4.1 Tóm tắt kết quả phân tích:

Số ca mắc, tử vong và hồi phục có sự phân bố không đồng đều giữa các châu lục. Châu Á và châu Âu có số ca mắc cao nhất, trong khi châu Phi có tỷ lệ tử vong thấp hơn.

Dữ liệu cho thấy sự tương quan giữa dân số và số ca mắc: các quốc gia có dân số cao thường ghi nhận nhiều ca mắc hơn.

Các quốc gia có số lượng xét nghiệm lớn thường có số ca ghi nhận cao hơn, cho thấy sự ảnh hưởng của khả năng xét nghiệm đối với số liệu thực tế.

Biểu đồ z-score giúp phát hiện những giá trị ngoại lệ, từ đó có thể nhận diện các khu vực có tình hình dịch bệnh bất thường so với mặt bằng chung.

4.2 Đánh giá những hạn chế của phân tích:

Dữ liệu thu thập có thể chưa phản ánh đầy đủ thực trạng do phụ thuộc vào khả năng xét nghiệm và báo cáo của từng quốc gia.

Một số dữ liệu bị thiếu hoặc không chính xác, đòi hỏi phải xử lý và ước lượng, có thể làm giảm độ chính xác của kết quả.

Các yếu tố khác như hệ thống y tế, điều kiện kinh tế - xã hội, chính sách kiểm soát dịch bệnh chưa được đưa vào phân tích, trong khi đây là những yếu tố quan trọng quyết định số ca nhiễm và tử vong.

4.3 Đề xuất các hướng nghiên cứu tiếp theo:

Mở rộng phạm vi phân tích bằng cách tích hợp thêm các biến số như điều kiện y tế, tỷ lệ tiêm chủng, và biện pháp phong tỏa của từng quốc gia.

Xây dựng mô hình dự báo xu hướng dịch bệnh bằng các thuật toán Machine Learning để đưa ra nhận định về tình hình trong tương lai.

Thực hiện so sánh sâu hơn giữa các khu vực dựa trên các yếu tố kinh tế - xã hội nhằm tìm ra mối liên hệ giữa mức độ phát triển của một quốc gia và khả năng kiểm soát dịch bệnh.

5 Tài liệu tham khảo:

1. Kaggle COVID-19 Dataset: <https://www.kaggle.com/datasets/sanaafrine/covid-19-dataset>

2. World Health Organization (WHO): <https://www.who.int/emergencies/diseases/novel-coronavirus-2019>
3. John Hopkins University COVID-19 Dashboard: <https://coronavirus.jhu.edu/>
4. Seaborn Documentation (Visualization): <https://seaborn.pydata.org/>
5. <https://chatgpt.com/>
6. <https://gemini.google.com/?hl=vi>