

**TRƯỜNG ĐẠI HỌC VĂN LANG
KHOA CÔNG NGHỆ THÔNG TIN**



**Data Analytics and Deep Learning
NGÀNH: CÔNG NGHỆ THÔNG TIN**

Đề tài:

**Application of CNN models for fashion apparel
classification**

SVTH: Nguyễn Thành Tài – 2274802010773

Nguyễn Quốc Lâm - 2274802010470

GVHD: Thầy Nguyễn Thái Anh

LHP: 242_71ITDS30203_0504

TP. Hồ Chí Minh – năm 2025

Mục Lục

1	Giới Thiệu:	5
1.1	Giới thiệu tổng quan về mô hình:	5
1.2	Lý do chọn đề tài:	5
1.3	Mục tiêu và phạm vi nghiên cứu:	5
1.3.1	Mục tiêu nghiên cứu:	5
1.3.2	Phạm vi nghiên cứu:	5
2	Cơ sở lý thuyết:	6
2.1	Tổng quan về học sâu và CNN:	6
2.2	Khái niệm về CNN:	6
2.2.1	Ưu điểm của CNN trong xử lý ảnh:	6
2.3	Kiến trúc cơ bản của CNN:	7
2.4	Các lớp tích chập (Convolutional Layers):	8
2.4.1	Các lớp tích gộp (Pooling Layers):	8
2.4.2	Các lớp kết nối đầy đủ (Fully Connected Layers):	9
2.4.3	Hàm kích hoạt Softmax:	9
2.5	Hàm mất mát và thuật toán tối ưu hóa:	10
2.5.1	Hàm mất mát Cross-Entropy:	10
2.5.2	Thuật toán lan truyền ngược:	11
2.5.3	Các thuật toán tối ưu hóa (Adam, SGD, v.v.):	11
3	Xây dựng mô hình CNN:	12
3.1	Mô tả tập dữ liệu:	12
3.2	Tiền xử lý dữ liệu:	12
3.2.1	Chuẩn hóa dữ liệu:	13
3.3	Thiết kế cấu trúc mô hình CNN:	15
3.3.1	Lựa chọn số và kích thước của các lớp:	15
3.3.2	Huấn luyện mô hình:	17
4	Đánh giá mô hình và Kết quả:	18
4.1	Đánh giá mô hình:	18

4.1.1	Độ chính xác (Accuracy):	18
4.1.2	Hàm mất mát (LossFunction):	19
4.2	Kết quả mô hình:	19
4.2.1	Hiệu suất mô hình:	19
5	Hướng phát triển:	20
5.1	Tiềm năng phát triển:	20
5.2	Đề xuất hướng nghiên cứu tiếp theo:.....	21
6	Kết luận:	21
6.1	Kết quả đạt được:	22
6.2	Ý nghĩa của mô hình:	23
7	Tài liệu tham khảo:	23
8	Phụ lục hình ảnh	24

Lời cảm ơn!

Kính gửi Thầy Nguyễn Thái Anh,

Em xin gửi lời cảm ơn chân thành và sâu sắc nhất đến thầy vì sự hướng dẫn và hỗ trợ tận tình của thầy trong suốt quá trình em thực hiện bài báo cáo này. Những kiến thức quý báu, những lời khuyên hữu ích và sự động viên từ thầy đã giúp em vượt qua những khó khăn và hoàn thành bài báo cáo một cách tốt nhất.

Sự kiên nhẫn và tâm huyết của thầy đã truyền cảm hứng cho em rất nhiều. Em xin cảm ơn thầy đã luôn sẵn lòng giải đáp những thắc mắc của em, giúp em hiểu rõ hơn về đề tài nghiên cứu. Em xin trân trọng những lời nhận xét và góp ý của thầy, chúng đã giúp em hoàn thiện bài báo cáo và nâng cao kiến thức của mình.

Em xin kính chúc thầy luôn mạnh khỏe, hạnh phúc và thành công trong sự nghiệp. Em xin hứa sẽ cố gắng học tập và nghiên cứu để không phụ lòng mong mỏi của thầy.

1 Giới Thiệu:

1.1 Giới thiệu tổng quan về mô hình:

CNN là một công cụ mạnh mẽ và hiệu quả trong việc phân loại hình ảnh nói chung và đặc biệt là phân loại hình ảnh về quần áo. Có khả năng ứng dụng vào thực tế cao, phù hợp cho nhiều ngành nghề và nhiều lĩnh vực liên quan. Mô hình mạng Nơ-ron tích chập (Convolutional Neutral Network - CNN) là một loại mạng nơ-ron nhân tạo đặc biệt hiệu quả trong việc xử lý và phân tích hình ảnh. Trong lĩnh vực phân loại quần áo, CNN đã chứng minh được khả năng vượt trội, giúp máy tính nhận diện và phân loại các loại trang phục một cách chính xác.

1.2 Lý do chọn đề tài:

Việc lựa chọn đề tài ứng dụng mô hình CNN để phân loại quần áo xuất phát từ nhiều lý do quan trọng, kết hợp giữa tính ứng dụng thực tiễn cao và sự phát triển mạnh mẽ của công nghệ ngày nay. Tính ứng dụng cao trong thực tiễn: Thương mại điện tử, ngành công nghiệp thời trang, những hệ thống nhận diện hình ảnh,... Việc lựa chọn đề tài này không chỉ mang tính ứng dụng cao mà còn tận dụng được những ưu điểm vượt trội của mô hình CNN, đồng thời phù hợp với xu hướng phát triển của công nghệ hiện nay.

1.3 Mục tiêu và phạm vi nghiên cứu:

1.3.1 Mục tiêu nghiên cứu:

Xây dựng và phát triển mô hình CNN hiệu quả:

Mục tiêu chính là tạo ra mô hình CNN có khả năng phân loại quần áo với độ chính xác cao. Tìm hiểu nhiều các cấu trúc CNN khác nhau, các kỹ thuật tối ưu hóa và các phương pháp tiền xử lý dữ liệu để cải thiện hiệu suất của mô hình.

Áp dụng mô hình CNN vào các lĩnh vực trong cuộc sống và xã hội. Tự động hóa quá trình phân loại quần áo, giúp tiết kiệm thời gian và nhân lực.

1.3.2 Phạm vi nghiên cứu:

Dữ liệu:

Tập trung vào việc sử dụng các tập dữ liệu hình ảnh về quần áo, chẳng hạn như FASHION-MNIST, hoặc các tập dữ liệu tùy chỉnh.

Nghiên cứu các phương pháp thu thập, tiền xử lý và tăng cường dữ liệu để cải thiện chất lượng dữ liệu đầu vào.

Mô hình:

Tìm hiểu và khám phá các cấu trúc CNN phổ biến cũng như các cấu trúc mới nhất.

Nghiên cứu các kỹ thuật tối ưu hóa như tối ưu hóa những tham số, điều chỉnh tốc độ học và các phương pháp chính quy hóa.

Phân tích và so sánh hiệu suất của các mô hình CNN khác nhau trên các tập dữ liệu quần áo.

Phạm vi nghiên cứu sẽ bao gồm việc phát triển mô hình, xử lý dữ liệu, và triển khai ứng dụng. Mục tiêu tạo ra một hệ thống phân loại quần áo tự động và có hiệu quả cao và có tính ứng dụng cao trong thực tiễn.

2 Cơ sở lý thuyết:

2.1 Tổng quan về học sâu và CNN:

Mạng nơ-ron tích chập (Convolutional Neural Network - CNN) là một trong những mô hình phổ biến và hiệu quả nhất trong xử lý hình ảnh. CNN có khả năng tự động học và trích xuất các đặc trưng từ ảnh, giúp cải thiện đáng kể độ chính xác so với các mô hình truyền thống.


2.2 Khái niệm về CNN:

CNN là từ viết tắt của cụm Convolutional Neural Network hay là mạng nơ ron tích chập. Đây là mô hình vô cùng tiên tiến được áp dụng nhiều trong lĩnh vực học sâu(Deep Learning). Mạng nơ ron này cho phép người dùng xây dựng những hệ thống phân loại và dự đoán với độ chính xác cực cao. Hiện nay, mạng CNN được ứng dụng nhiều hơn trong xử lý ảnh, cụ thể là nhận diện đối tượng trong ảnh.

2.2.1 Ưu điểm của CNN trong xử lý ảnh:

CNN có khả năng xử lý hình ảnh phức tạp với độ phân giải cao một cách chính xác và hiệu quả. Bằng việc lặp lại các lớp tích chập, CNN có thể tự học và trích xuất được những đặc trưng của hình ảnh chẳng hạn như đường viền, góc cạnh, kết cấu và các mẫu hình ảnh phức tạp hơn, nhờ vậy mà giúp cho mô hình có thể tự phân loại và nhận diện đối tượng hiệu quả hơn. Điều này giúp giảm bớt nhu cầu tiền xử lý dữ liệu thủ công, vốn tốn nhiều thời gian và công sức.

2.3 Kiến trúc cơ bản của CNN:



Hình 1 Kiến trúc cơ bản của CNN


Mạng CNN là tập hợp những Convolutional layer xếp chồng lên nhau, đồng thời mạng sử dụng những hàm như ReLU và Tanh để kích hoạt các trọng số trong các node. Các lớp này sau khi qua các hàm activation sẽ có trọng số trong những node và có thể tạo ra những thông tin trừu tượng hơn đến với các lớp kế tiếp trong mạng.

Mạng này có tính kết hợp cả tính bất biến. Tức là, nếu cùng một đối tượng mà sử dụng chiếu theo các góc độ khác nhau thì sẽ có ảnh hưởng đến độ chính xác. Với dịch chuyển, co giãn hay quay ma trận ảnh thì lớp Pooling sẽ được dùng để hỗ trợ làm bất biến các tính chất này. Chính vì vậy mà mạng nơ ron này sẽ đưa ra những kết quả có độ chính xác tương ứng với từng mô hình.

Trong đó, lớp Pooling sẽ có khả năng tạo tính bất biến với phép dịch chuyển, co giãn và quay. Còn tính kết hợp cục bộ sẽ cho thấy những cấp độ biểu diễn, dữ liệu từ thấp đến cao với mức trừu tượng thông qua Convolution từ filter. Mạng CNN có những lớp liên kết nhau dựa vào cơ chế Convolution.

Các lớp tiếp theo sẽ là kết quả từ những lớp trước đó, vì vậy mà bạn sẽ có những liên kết cục bộ phù hợp nhất. Trong quá trình huấn luyện mạng, mạng nơ ron này sẽ tự học hỏi những giá trị thông qua filter layer dựa theo cách thức mà bạn thực hiện.


2.4 Các lớp tích chập (Convolutional Layers):



Hình 2 Convolutional Layers

Đây là lớp cốt lõi của CNN, nơi các bộ lọc (filter) hoặc kernel được áp dụng lên hình ảnh đầu vào để trích xuất các đặc trưng quan trọng. Mỗi bộ lọc sẽ quét qua hình ảnh, thực hiện phép tích chập (convolution) để tạo ra một bản đồ đặc trưng (feature map). Các bộ lọc có thể học được các đặc trưng khác nhau, chẳng hạn như đường viền, góc cạnh, kết cấu, và các mẫu hình ảnh phức tạp hơn. Tầng tích chập giúp mô hình nhận diện các mẫu hình ảnh đặc trưng cho từng loại quần áo.


2.4.1 Các lớp tích gộp (Pooling Layers):



Hình 3 Pooling Layers

Tầng gộp được sử dụng để giảm kích thước của các bản đồ đặc trưng, giúp giảm tải tính toán và tăng tính tổng quát của mô hình. Các phương pháp gộp phổ biến bao gồm gộp cực đại (max pooling) và gộp trung bình (average pooling). Gộp cực đại lấy giá trị lớn nhất trong một vùng cửa sổ, trong khi gộp trung bình lấy giá trị trung bình. Tầng gộp giúp mô hình tập trung vào các đặc trưng quan trọng nhất trong hình ảnh.

2.4.2 Các lớp kết nối đầy đủ (Fully Connected Layers):



Hình 4 Fully Connected Layers

Ở giai đoạn cuối, các bản đồ đặc trưng đã được trích xuất và gộp lại sẽ được làm phẳng (flatten) và đưa vào các tầng kết nối đầy đủ. Tại đây, mô hình sẽ học cách kết hợp các đặc trưng để đưa ra dự đoán phân loại cuối cùng. Tầng kết nối đầy đủ hoạt động tương tự như các tầng trong mạng nơ-ron truyền thống.

2.4.3 Hàm kích hoạt Softmax:

SOFTMAX FUNCTION

$$s(x_i) = \frac{e^{x_i}}{\sum_{j=1}^n e^{x_j}}$$

Hình 5 Hàm SoftMax

Hàm Softmax cho phép mô hình học sâu đưa ra các dự đoán xác suất, giúp hiểu rõ hơn về độ tin cậy của các dự đoán. Hàm Softmax chuyển đổi một vector các giá trị thực thành một

vector xác suất, trong đó mỗi giá trị đại diện cho xác suất của một lớp cụ thể. Nói cách khác, nó biến đổi đầu ra của một lớp nơ-ron thành một phân phối xác suất trên các lớp đầu ra.

2.5 Hàm mất mát và thuật toán tối ưu hóa:

Thuật toán lan truyền ngược (Backpropagation): Giúp điều chỉnh trọng số của các nơ-ron để mô hình học tốt hơn. Thuật toán tối ưu hóa (Adam, SGD, v.v.): Được sử dụng để cập nhật trọng số nhanh hơn và tăng hiệu suất học của mô hình.

2.5.1 Hàm mất mát Cross-Entropy:

Cross-entropy đo lường sự khác biệt giữa hai phân phối xác suất. Trong học sâu, nó thường được sử dụng để đo lường sự khác biệt giữa phân phối xác suất dự đoán của mô hình và phân phối xác suất thực tế của nhãn.

Mục tiêu của việc đào tạo mô hình là giảm thiểu giá trị của hàm mất mát Cross-entropy, tức là làm cho phân phối xác suất dự đoán của mô hình càng gần với phân phối xác suất thực tế càng tốt.

Công thức:

Đối với bài toán phân loại nhị phân (binary classification):

$$\text{Loss} = -[y * \log(p) + (1 - y) * \log(1 - p)]$$

Trong đó:

- y là nhãn thực tế (0 hoặc 1).
- p là xác suất dự đoán của mô hình cho nhãn 1.


Đối với bài toán phân loại đa lớp (multi-class classification):

$$\text{Loss} = -\sum(y_i * \log(p_i))$$

Trong đó:

- y_i là nhãn thực tế của lớp i (0 hoặc 1).
- p_i là xác suất dự đoán của mô hình cho lớp i .
- Σ là tổng của tất cả các lớp.

2.5.2 Thuật toán lan truyền ngược:



Hình 6 Backpropagation

Thuật toán lan truyền ngược (backpropagation) là một trong những thuật toán cốt lõi của học sâu, được sử dụng để đào tạo các mạng nơ-ron nhân tạo (neural network), đặc biệt là các mạng nơ-ron sâu (deep neural network). Mục tiêu chính của thuật toán lan truyền ngược là tối ưu hóa các trọng số (weights) và độ lệch (biases) của mạng nơ-ron để giảm thiểu hàm mất mát (loss function). Hàm mất mát đo lường sự khác biệt giữa đầu ra dự đoán của mạng nơ-ron và đầu ra thực tế của dữ liệu huấn luyện. Bằng cách giảm thiểu hàm mất mát, mạng nơ-ron có thể đưa ra các dự đoán chính xác hơn.

2.5.3 Các thuật toán tối ưu hóa (Adam, SGD, v.v.):

Stochastic Gradient Descent (SGD):

SGD khắc phục nhược điểm của GD bằng cách cập nhật tham số dựa trên gradient của một mẫu dữ liệu ngẫu nhiên hoặc một mini-batch (nhóm nhỏ) dữ liệu.

Ưu điểm: Hội tụ nhanh hơn GD, ít tốn kém về mặt tính toán.

Nhược điểm: Dao động lớn, khó hội tụ chính xác.

Adam (Adaptive Moment Estimation):

Adam là một thuật toán tối ưu hóa thích nghi, kết hợp ưu điểm của SGD và RMSProp (Root Mean Square Propagation). Adam tính toán các ước lượng thích nghi cho cả gradient bậc nhất và bậc hai, giúp điều chỉnh tốc độ học (learning rate) cho từng tham số.

Ưu điểm: Hội tụ nhanh, hiệu quả với nhiều loại mô hình, ít yêu cầu điều chỉnh tham số.

Nhược điểm: Có thể không hội tụ tốt trong một số trường hợp cụ thể.

3 Xây dựng mô hình CNN:

3.1 Mô tả tập dữ liệu:

Link : <https://www.kaggle.com/datasets/zalando-research/fashionmnist/data>

Fashion-MNIST là một tập dữ liệu hình ảnh bài viết của Zalando—bao gồm một tập huấn luyện gồm 60.000 ví dụ và một tập kiểm tra gồm 10.000 ví dụ. Mỗi ví dụ là một hình ảnh thang độ xám 28x28, được liên kết với một nhãn từ 10 lớp. Zalando dự định Fashion-MNIST sẽ đóng vai trò là sự thay thế trực tiếp cho tập dữ liệu MNIST gốc để đánh giá chuẩn các thuật toán học máy. Nó có cùng kích thước hình ảnh và cấu trúc của các phần đào tạo và kiểm tra.

3.2 Tiền xử lý dữ liệu:

Tiền xử lý dữ liệu hình ảnh là một bước quan trọng trong quá trình xây dựng các mô hình học máy và học sâu, đặc biệt là trong lĩnh vực thị giác máy tính. Mục tiêu của tiền xử lý là cải thiện chất lượng dữ liệu đầu vào, giúp mô hình học hiệu quả hơn và đạt được độ chính xác cao hơn.

Tạo label số tương ứng với trang phục

```
#Tạo label số tương ứng với trang phục
fashion_mnist_labels = {
    0: "T-shirt/top",
    1: "Trouser",
    2: "Pullover",
    3: "Dress",
    4: "Coat",
    5: "Sandal",
    6: "Shirt",
    7: "Sneaker",
    8: "Bag",
    9: "Ankle boot"
}
```

Hình 7Tạo Label


Lấy hàng đầu tiên từ DataFrame chứa dữ liệu Fashion-MNIST, trích xuất hình ảnh và nhãn của nó, chuyển đổi hình ảnh thành ma trận 28x28, và hiển thị hình ảnh thang độ xám với tiêu đề chứa tên nhãn.

Chuyển đổi dữ liệu thành một mảng Numpy. Để thực hiện các phép toán số học và định lại mảng.

Định hình lại mảng Numpy thành một ma trận 28x28. Do hình ảnh trong dữ liệu có kích thước 28x28 pixel.

```
image = df.iloc[0, 1:].to_numpy().reshape(28, 28)
image_label = fashion_mnist_labels[df.iloc[0, 0]]

plt.imshow(image, cmap='gray')
plt.title(f"Label: {image_label}")
plt.show()
```



Hình 8 Định hình lại mảng

3.2.1 Chuẩn hóa dữ liệu:

Chuẩn hóa dữ liệu hình ảnh cho cả tập huấn luyện và tập kiểm tra bằng cách chia các giá trị pixel cho 255.0. Điều này giúp đưa các giá trị pixel về phạm vi [0, 1], giúp cải thiện hiệu suất của mô hình. Ngoài ra, nó cũng trích xuất các nhãn hình ảnh từ DataFrame và gán chúng cho các biến `y` và `y_test`.

```
# Chuẩn hoá giá trị pixel từ phạm vi (0-255) đến (0-1):
X = df.iloc[:, 1:] / 255.0
y = df.iloc[:, 0]

X_test = df_test.iloc[:, 1:] / 255.0
y_test = df_test.iloc[:, 0]
```

Hình 9 Chuẩn hóa dữ liệu

Định dạng lại dữ liệu hình ảnh từ dạng 2D (số lượng hình ảnh, số lượng pixel) sang dạng 4D (số lượng hình ảnh, chiều cao, chiều rộng, số kênh màu), là định dạng đầu vào cần thiết cho hầu hết các mô hình CNN.

```
# Định dạng hình ảnh để phù hợp với mô hình CNN:
X = X.values.reshape(-1, 28, 28, 1)
X_test = X_test.values.reshape(-1, 28, 28, 1)
```

Hình 10 Định dạng hình ảnh

Mã hóa các nhãn phân loại thành các giá trị số liên tục, giúp mô hình học máy có thể xử lý chúng. Việc sử dụng `fit_transform()` cho tập huấn luyện và `transform()` cho tập kiểm tra đảm bảo rằng các nhãn được mã hóa một cách nhất quán.

```
#Mã hoá nhãn bằng LabelEncoder:
from sklearn.preprocessing import LabelEncoder

label_encoder = LabelEncoder()
y = label_encoder.fit_transform(y)
y_test = label_encoder.transform(y_test)
```

Hình 11 Mã hóa nhãn

Chia dữ liệu thành ba tập: huấn luyện, xác thực và kiểm tra, giúp đánh giá và tối ưu hóa mô hình một cách chính xác. Việc chia dữ liệu như vậy là rất quan trọng trong học máy để tránh tình trạng quá khớp (overfitting) và đánh giá khả năng tổng quát hóa của mô hình.

```
from sklearn.model_selection import train_test_split

# Chia dữ liệu thành các tập huấn luyện, xác thực và kiểm tra:
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
X_train, X_val, y_train, y_val = train_test_split(X_train, y_train, test_size=0.2, random_state=42)

# Hiển thị hình dạng tập dữ liệu
print("X_train shape:", X_train.shape)
print("X_val shape:", X_val.shape)
print("X_test shape:", X_test.shape)
print("=====")
print("y_train shape:", y_train.shape)
print("y_val shape:", y_val.shape)
print("y_test shape:", y_test.shape)

X_train shape: (38400, 28, 28, 1)
X_val shape: (9600, 28, 28, 1)
X_test shape: (12000, 28, 28, 1)
=====
y_train shape: (38400,)
y_val shape: (9600,)
y_test shape: (12000,)
```

Hình 12 Chia dữ liệu

3.3 Thiết kế cấu trúc mô hình CNN:

Định nghĩa một mô hình Mạng Nơ-ron Tích chập (CNN) sử dụng TensorFlow Keras. Mô hình CNN tuần tự với các lớp tích chập, gộp, chuẩn hóa lô, dropout và kết nối đầy đủ.

```
#Xây dựng mô hình CNN
import tensorflow as tf

model = tf.keras.Sequential([
    tf.keras.layers.Conv2D(64, (3,3), activation='relu', input_shape=(28, 28, 1)),
    tf.keras.layers.BatchNormalization(),
    tf.keras.layers.Conv2D(64, (3,3), activation='relu'),
    tf.keras.layers.MaxPooling2D((2,2)),
    tf.keras.layers.Dropout(0.25),

    tf.keras.layers.Conv2D(32, (3,3), activation='relu'),
    tf.keras.layers.BatchNormalization(),
    tf.keras.layers.Conv2D(32, (3,3), activation='relu'),
    tf.keras.layers.MaxPooling2D((2,2)),
    tf.keras.layers.Dropout(0.25),
    tf.keras.layers.Flatten(),
    #tf.keras.layers.GlobalAveragePooling2D(),
    tf.keras.layers.Dense(256, activation='relu'),
    tf.keras.layers.BatchNormalization(),
    tf.keras.layers.Dropout(0.5),
    tf.keras.layers.Dense(10, activation='softmax')
])
```

Hình 13 Xây dựng mô hình

Định nghĩa thuật toán tối ưu hóa, hàm mất mát và các metrics đánh giá hiệu suất của mô hình, các trọng số của mô hình sẽ được cập nhật để giảm thiểu hàm mất mát và cải thiện độ chính xác.

```
• #cấu hình mô hình:
model.compile(optimizer='adam', loss='sparse_categorical_crossentropy', metrics=['accuracy'])
```

Hình 14 Cấu hình mô hình

3.3.1 Lựa chọn số và kích thước của các lớp:

Lớp tích chập đầu tiên (Conv2D(64, (3,3))):

- **64 bộ lọc:**

Đây là một lựa chọn phổ biến cho các bài toán phân loại hình ảnh.

- **(3,3) kernel:**

Kích thước kernel 3x3 là một lựa chọn phổ biến vì nó cho phép mô hình học các đặc trưng cục bộ mà không quá tốn kém về mặt tính toán.

Lớp BatchNormalization:

- Lớp này giúp ổn định quá trình huấn luyện và tăng tốc độ hội tụ.

Lớp tích chập thứ hai (Conv2D(64, (3,3))):

- **64 bộ lọc:**

Việc sử dụng cùng số lượng bộ lọc như lớp đầu tiên cho phép mô hình tiếp tục học các đặc trưng phức tạp hơn.

Lớp MaxPooling2D((2,2)):

- **(2,2) pooling:**

Kích thước pooling 2x2 là một lựa chọn phổ biến vì nó giảm kích thước không gian của các bản đồ đặc trưng một cách hiệu quả.

Lớp Dropout(0.25):

- **0.25 dropout rate:**

Tỷ lệ dropout 0.25 là một lựa chọn phổ biến để ngăn chặn tình trạng overfitting.

Lớp tích chập thứ ba (Conv2D(32, (3,3))):

- **32 bộ lọc:**

Giảm số lượng bộ lọc xuống 32 ở các lớp sau giúp giảm số lượng tham số và thời gian huấn luyện.

Lớp BatchNormalization:

- Lớp này giúp ổn định quá trình huấn luyện và tăng tốc độ hội tụ.

Lớp tích chập thứ tư (Conv2D(32, (3,3))):

- **32 bộ lọc:**

Giống như lớp tích chập thứ ba.

Lớp MaxPooling2D((2,2)) và Dropout(0.25):

- Giống như các lớp MaxPooling và Dropout trước đó.

Lớp Flatten():

- Lớp này chuyển đổi các bản đồ đặc trưng 2D thành một vector 1D, chuẩn bị cho các lớp kết nối đầy đủ.

Lớp Dense(256):

- **256 nơ-ron:**

Số lượng nơ-ron này là một lựa chọn phổ biến cho các lớp kết nối đầy đủ.

Lớp BatchNormalization và Dropout(0.5):

- Dropout rate 0.5 là cao hơn so với lớp dropout trước, do lớp dense này có nhiều tham số, và nguy cơ overfitting cao hơn.

Lớp Dense(10):

- **10 nơ-ron:**

Số lượng nơ-ron này tương ứng với số lượng lớp đầu ra (10 lớp quần áo trong Fashion-MNIST).

3.3.2 Huấn luyện mô hình:

Huấn luyện mô hình CNN trên dữ liệu huấn luyện, đánh giá hiệu suất của mô hình trên dữ liệu xác thực sau mỗi epoch và lưu trữ thông tin về quá trình huấn luyện trong đối tượng history. Sau đó, nó trích xuất giá trị của hàm mất mát trên cả tập huấn luyện và tập xác thực để phân tích và đánh giá hiệu suất của mô hình.

```
• #Train mô hình:  
history = model.fit(X_train, y_train, epochs=50, validation_data=(X_val, y_val))  
train_loss = history.history['loss']  
val_loss = history.history['val_loss']
```

Hình 15Huấn luyện mô hình


```
Epoch 1/50  
1200/1200 — 34s 26ms/step - accuracy: 0.6661 - loss: 1.0297 - val_accuracy: 0.8523 - val_loss: 0.3961  
Epoch 2/50  
1200/1200 — 32s 26ms/step - accuracy: 0.8333 - loss: 0.4518 - val_accuracy: 0.8790 - val_loss: 0.3311  
Epoch 3/50  
1200/1200 — 34s 28ms/step - accuracy: 0.8598 - loss: 0.3861 - val_accuracy: 0.8942 - val_loss: 0.2974  
Epoch 4/50  
1200/1200 — 32s 27ms/step - accuracy: 0.8737 - loss: 0.3462 - val_accuracy: 0.9014 - val_loss: 0.2743  
Epoch 5/50  
1200/1200 — 32s 26ms/step - accuracy: 0.8822 - loss: 0.3269 - val_accuracy: 0.9057 - val_loss: 0.2701  
Epoch 6/50  
1200/1200 — 33s 27ms/step - accuracy: 0.8891 - loss: 0.3097 - val_accuracy: 0.8966 - val_loss: 0.2874  
Epoch 7/50  
1200/1200 — 33s 28ms/step - accuracy: 0.8939 - loss: 0.2927 - val_accuracy: 0.9008 - val_loss: 0.2811  
Epoch 8/50  
1200/1200 — 34s 28ms/step - accuracy: 0.9029 - loss: 0.2706 - val_accuracy: 0.9140 - val_loss: 0.2399  
Epoch 9/50  
1200/1200 — 33s 28ms/step - accuracy: 0.9035 - loss: 0.2677 - val_accuracy: 0.9192 - val_loss: 0.2301  
Epoch 10/50  
1200/1200 — 32s 27ms/step - accuracy: 0.9094 - loss: 0.2532 - val_accuracy: 0.9205 - val_loss: 0.2219  
Epoch 11/50  
1200/1200 — 33s 27ms/step - accuracy: 0.9096 - loss: 0.2483 - val_accuracy: 0.9191 - val_loss: 0.2254  
Epoch 12/50  
1200/1200 — 32s 27ms/step - accuracy: 0.9120 - loss: 0.2425 - val_accuracy: 0.9215 - val_loss: 0.2294  
Epoch 13/50  
...  
Epoch 49/50  
1200/1200 — 32s 26ms/step - accuracy: 0.9523 - loss: 0.1283 - val_accuracy: 0.9293 - val_loss: 0.2154  
Epoch 50/50  
1200/1200 — 32s 27ms/step - accuracy: 0.9482 - loss: 0.1415 - val_accuracy: 0.9317 - val_loss: 0.2154  
Output is truncated. View as a scrollable element or open in a text editor. Adjust cell output settings...
```

Hình 16Kết quả huấn luyện

4 Đánh giá mô hình và Kết quả:

4.1 Đánh giá mô hình:

4.1.1 Độ chính xác (Accuracy):




Hình 17 Biểu đồ Train&Test Accuracy

Độ chính xác trên tập huấn luyện (accuracy) tăng dần qua các epoch, đạt mức cao (khoảng 94-95%) ở những epoch cuối.

Độ chính xác trên tập xác thực (val_accuracy) cũng tăng dần, đạt mức cao (khoảng 92-93%) ở những epoch cuối.

Điều này cho thấy mô hình học tốt trên cả dữ liệu huấn luyện và dữ liệu xác thực.

4.1.2 Hàm mất mát (LossFunction):



Hình 18 Biểu đồ Train&Test Loss

Hàm mất mát trên tập huấn luyện (loss) giảm dần qua các epoch, cho thấy mô hình đang học cách giảm thiểu sai số.

Hàm mất mát trên tập xác thực (val_loss) cũng giảm dần, nhưng có một số dao động nhỏ. Val_loss có giá trị thấp, điều này là một dấu hiệu tốt.

4.2 Kết quả mô hình:

4.2.1 Hiệu suất mô hình:

```
#Đánh giá mô hình:
test_loss, test_acc = model.evaluate(X_test, y_test)

print('Test accuracy:', test_acc)
print("Test loss:", test_loss)
```

```
375/375 ————— 2s 6ms/step - accuracy: 0.9322 - loss: 0.2019
Test accuracy: 0.9303333163261414
Test loss: 0.2098948210477829
```

Hình 19 Đánh giá mô hình

Có một sự khác biệt nhỏ giữa độ chính xác trên tập huấn luyện và độ chính xác trên tập xác thực. Tuy nhiên, sự khác biệt này không quá lớn, cho thấy mô hình không bị quá khớp nghiêm trọng.

Val_loss và loss có sự tương đồng trong quá trình giảm, nên ta có thể kết luận mô hình không bị overfitting.

Độ chính xác trên tập xác thực đạt mức cao (khoảng 92-93%), cho thấy mô hình có khả năng tổng quát hóa tốt trên dữ liệu chưa thấy.

Hàm mất mát trên tập xác thực cũng ở mức thấp, cho thấy mô hình dự đoán chính xác.

5 Hướng phát triển:

5.1 Tiềm năng phát triển:

Mô hình Mạng Nơ-ron Tích chập (CNN) đang chứng tỏ tiềm năng phát triển mạnh mẽ trong lĩnh vực phân loại quần áo, mở ra nhiều cơ hội ứng dụng trong thực tiễn.

Tăng cường trải nghiệm mua sắm trực tuyến:

- **Phân loại và tìm kiếm thông minh:**

CNN có thể cải thiện đáng kể khả năng phân loại và tìm kiếm quần áo trên các nền tảng thương mại điện tử. Người dùng có thể dễ dàng tìm kiếm sản phẩm theo kiểu dáng, màu sắc, chất liệu và các đặc điểm khác một cách trực quan.

- **Gợi ý sản phẩm cá nhân hóa:**

CNN có thể phân tích hình ảnh quần áo mà người dùng quan tâm để đưa ra các gợi ý sản phẩm tương tự hoặc phù hợp với phong cách cá nhân. Điều này giúp tăng tỷ lệ chuyển đổi và sự hài lòng của khách hàng.

- **Thử đồ ảo:**

Kết hợp CNN với công nghệ thực tế tăng cường (AR), người dùng có thể thử đồ ảo ngay trên thiết bị di động. Điều này giúp giảm thiểu tình trạng mua hàng không phù hợp và tăng sự tự tin khi mua sắm trực tuyến.

Ứng dụng trong ngành công nghiệp thời trang:

- **Tự động hóa quy trình kiểm tra chất lượng:**

CNN có thể tự động kiểm tra các lỗi trên quần áo, giúp tiết kiệm thời gian và chi phí cho các nhà sản xuất. Điều này đảm bảo chất lượng sản phẩm đồng đều và giảm thiểu hàng lỗi.

- **Phân tích xu hướng thời trang:**

CNN có thể phân tích hình ảnh từ các sàn diễn thời trang và mạng xã hội để nhận diện các xu hướng mới. Điều này giúp các nhà thiết kế và nhà sản xuất nhanh chóng nắm bắt và đáp ứng nhu cầu thị trường.

- **Quản lý kho hàng thông minh:**

CNN có thể tự động nhận diện và phân loại quần áo trong kho hàng, giúp tối ưu hóa quy trình quản lý và giảm thiểu sai sót.

Mô hình CNN có tiềm năng phát triển rất lớn trong lĩnh vực phân loại quần áo, mang lại nhiều lợi ích cho người tiêu dùng, các nhà sản xuất và các ngành công nghiệp liên quan.

5.2 Đề xuất hướng nghiên cứu tiếp theo:

Để nâng cao hiệu suất và mở rộng ứng dụng của mô hình CNN trong phân loại quần áo, có một số hướng nghiên cứu tiếp theo tiềm năng như:

Cải thiện mô hình:

- Sử dụng các cấu trúc CNN tiên tiến hơn.
- Tối ưu hóa các siêu tham số.
- Kết hợp các mô hình.

Tăng cường dữ liệu và xử lý dữ liệu:

- Tăng cường dữ liệu nâng cao và phức tạp hơn.
- Xử lý dữ liệu không cân bằng.
- Sử dụng nhiều dữ liệu đa phương thức.

Ứng dụng và mở rộng mô hình:

- Nhận diện và phân loại quần áo qua video.
- Triển khai trên nhiều thiết bị.
- Ứng dụng trong các lĩnh vực khác.

Tiếp tục cải thiện và mở rộng ứng dụng của mô hình CNN trong phân loại quần áo, mang lại nhiều lợi ích cho người dùng và các ngành công nghiệp liên quan.

6 Kết luận:

Hiệu suất tốt:

Mô hình CNN đã đạt được hiệu suất tốt trong việc phân loại quần áo. Điều này được thể hiện qua độ chính xác cao (accuracy) và hàm mất mát thấp (loss) trên cả tập huấn luyện và tập xác thực.

Hội tụ nhanh:

Mô hình hội tụ khá nhanh, với độ chính xác trên tập xác thực đạt mức cao (trên 90%) chỉ sau khoảng 10-15 epochs. Điều này cho thấy mô hình học hiệu quả và không cần quá nhiều epochs để đạt được hiệu suất tốt.

Khả năng tổng quát hóa tốt:

Độ chính xác trên tập xác thực (val_accuracy) đạt mức cao (khoảng 93%) ở epoch cuối, cho thấy mô hình có khả năng tổng quát hóa tốt trên dữ liệu chưa thấy. Sự chênh lệch giữa accuracy và val_accuracy không quá lớn, chứng tỏ mô hình không bị overfitting.

Hàm mất mát ổn định:


Hàm mất mát trên tập xác thực (val_loss) giảm dần và ổn định ở mức thấp, cho thấy mô hình dự đoán chính xác và không có dấu hiệu quá khớp.

6.1 Kết quả đạt được:

```
n_samples = 20
plt.figure(figsize=(10, 10))
for i in range(n_samples):
    plt.subplot(5, 4, i+1)
    image = X_test[i]
    image_label = fashion_mnist_labels[y_test[i]]
    prediction = model.predict(image.reshape(1, 28, 28, 1))
    predicted_label = fashion_mnist_labels[np.argmax(prediction)]

    plt.imshow(image.reshape(28, 28), cmap='gray')
    plt.title(f"Label: {image_label}\nPredicted: {predicted_label}")
    plt.axis('off')
plt.tight_layout()
plt.show()
```

Mô hình CNN đã được huấn luyện thành công và đạt được kết quả tốt trong việc phân loại quần áo. Nó có khả năng học hỏi tốt, tổng quát hóa tốt và hội tụ nhanh.



6.2 Ý nghĩa của mô hình:

Mô hình CNN (Convolutional Neural Network - Mạng Nơ-ron Tích chập) trong phân loại quần áo mang lại nhiều ý nghĩa quan trọng, không chỉ trong lĩnh vực công nghệ mà còn trong các ngành công nghiệp liên quan và cuộc sống hàng ngày.

Tự động hóa và tối ưu hóa quy trình:

- Tự động hóa phân loại
- Tối ưu hóa quản lý kho hàng
- Kiểm tra chất lượng tự động

Cải thiện trải nghiệm người dùng:

- Mua sắm trực tuyến thông minh
- Thử đồ ảo

7 Tài liệu tham khảo:

- <https://aptech.fpt.edu.vn/cnn-la-gi.html#:~:text=CNN%20l%C3%A0%20t%E1%BB%AB%20vi%E1%BA%BFt%20t%E1%BA%Aft,%C4%91%E1%BB%99%20ch%C3%ADnh%20x%C3%A1c%20c%E1%BB%B1c%20cao.>
- <https://lptech.asia/kien-thuc/convolutional-neural-network-la-gi-tim-hieu-ve-thuat-toan-cnn#:~:text=%C6%AFu%20%C4%91i%E1%BB%83m%20c%E1%BB%A7a%20CNN%3A,%C4%91%E1%BB%91i%20t%C6%B0%E1%BB%A3ng%20hi%E1%BB%87u%20qu%E1%BA%A3%20h%C6%A1n.>
- <https://gemini.google.com/>
- http://techsource-asia.com/resources/convolutional-neural-network-matlab/?utm_term=neural%20network&utm_campaign=Neural_Network_VN&utm_source=adwords&utm_medium=ppc&hsa_acc=5026247392&hsa_cam=18434588328&hsa_grp=144255165800&hsa_ad=624283484149&hsa_src=g&hsa_tgt=kwd-10607161&hsa_kw=neural%20network&hsa_mt=b&hsa_net=adwords&hsa_ver=3&gad_source=1&gclid=Cj0KCQjwqIm_BhDnARIsAKBYcmtbl1ivDxBj86Tg6KvDguODf4sODiGQ7ZIRA-RVWFxxwYJPZG0qOVQaAslXEALw_wcB
- <https://www.kaggle.com/datasets/zalando-research/fashionmnist/data>
- <https://chatgpt.com/>

- <https://openai.com/>
- <https://builtin.com/machine-learning/fully-connected-layer>
- <https://www.geeksforgeeks.org/backpropagation-in-neural-network/>

8 Phụ lục hình ảnh

Hình 1	Kiến trúc cơ bản của CNN	7
Hình 2	Convolutional Layers	8
Hình 3	Pooling Layers	8
Hình 4	Fully Connected Layers	9
Hình 5	Hàm SoftMax	9
Hình 6	Backpropagation	11
Hình 7	Tạo Label	12
Hình 8	Định hình lại mảng	13
Hình 9	Chuẩn hóa dữ liệu	13
Hình 10	Định dạng hình ảnh	14
Hình 11	Mã hóa nhãn	14
Hình 12	Chia dữ liệu	14
Hình 13	Xây dựng mô hình	15
Hình 14	Cấu hình mô hình	15
Hình 15	Huấn luyện mô hình	17
Hình 16	Kết quả huấn luyện	17
Hình 17	Biểu đồ Train&Test Accuracy	18
Hình 18	Biểu đồ Train&Test Loss	19
Hình 19	Đánh giá mô hình	19